

AI4PEACE — Neutralia

Sistemi di intelligenza artificiale, militarizzazione, bias geopolitici, alternative regionali, architetture cooperative. Documento di lavoro del Centro Studi. Versione 5, maggio 2026.

Introduzione. Stati neutrali, strumenti neutrali

Neutralia nasce dall'idea che la neutralità di un paese, intesa nel suo significato sostanziale e non meramente formale, non sia un'astensione dai conflitti, ma una postura attiva di mediazione, una scelta culturale e politica che richiede un'intera architettura di scelte coerenti. Un paese che voglia essere neutrale non può limitarsi a non firmare alleanze militari: deve costruire un'economia che non lo renda dipendente da un singolo blocco, un sistema informativo che non sia branca operativa della propaganda di un campo, un apparato culturale che sappia rappresentare le ragioni di tutte le parti in conflitto, una diplomazia che mantenga aperti i canali con interlocutori reciprocamente ostili. La neutralità sostanziale è, in altre parole, un progetto di civiltà. Riguarda non solo le scelte degli Stati, ma anche gli strumenti che gli Stati e i loro cittadini utilizzano per pensare, comunicare, conoscere il mondo.

Negli ultimi vent'anni si è affermato uno strumento nuovo che pervade ormai ogni dimensione della vita pubblica e privata: l'intelligenza artificiale generativa, e in particolare i grandi modelli linguistici (Large Language Models, LLM). Sono diventati la prima fonte di informazione consultata da centinaia di milioni di persone, il sostegno cognitivo dietro a decisioni educative, sanitarie, giuridiche, giornalistiche, militari. La domanda che questo documento intende affrontare è dunque ineludibile per qualunque progetto di neutralità: è possibile che uno strumento così pervasivo sia esso stesso neutrale? E se non lo è, cosa significa per un paese che voglia esserlo dipendere da strumenti cognitivi prodotti da paesi che neutrali non sono e non intendono essere?

Il documento si articola in cinque parti. La prima documenta la dimensione militare già concretizzata dell'intelligenza artificiale generativa, mostrando come i principali sistemi siano oggi parte integrante dell'apparato bellico di Stati Uniti, Israele, Regno Unito, Francia e dell'Alleanza Atlantica. La seconda analizza il livello sotterraneo dell'allineamento — i bias culturali, geopolitici, linguistici e di censura governativa che strutturalmente caratterizzano ogni modello in funzione del paese che lo produce. La terza mappa la geografia emergente degli LLM sovrani fuori dall'asse Stati Uniti-Cina-Unione Europea, mostrando come America Latina, Sud-est asiatico, Penisola arabica, subcontinente indiano e Africa subsahariana stiano costruendo proprie alternative, e perché nessuna di queste possa essere descritta come «neutrale» nel senso forte del termine. La quarta esplora la possibilità tecnica e i vincoli politici di un modello globale multi-hub, smontando l'illusione che la pluralità delle fonti basti

a produrre neutralità e proponendo tre architetture realisticamente costruibili. La quinta, infine, affronta la domanda decisiva: chi potrebbe essere l'interlocutore credibile per un progetto di intelligenza artificiale cooperativa transnazionale, capace di durare nel tempo e di non degradare politicamente?

Parte I. La situazione degli attuali sistemi di intelligenza artificiale e della loro militarizzazione

Nel momento in cui si sta scrivendo (maggio 2026), tutte le più importanti aziende che sviluppano intelligenza artificiale hanno stretto accordi con il settore militare di diversi Stati, finalizzando dunque la tecnologia verso un utilizzo bellico.

Ovviamente i primi ad aver utilizzato l'intelligenza artificiale per fini militari sono gli Stati Uniti, che hanno avviato diversi progetti in materia.

Project Maven, avviato nell'aprile del 2017, utilizza l'intelligenza artificiale per analizzare dati e identificare bersagli; vengono impiegati i software di OpenAI e Claude per mezzo di Palantir. Questo sistema è stato utilizzato in Iraq e in Siria negli scontri con l'ISIS, in Yemen e in Ucraina.

Titan, acronimo di Tactical Intelligence Targeting Access Node, avviato nel 2024 da Palantir, è un sistema che consente di collegare i sensori, vale a dire satelliti, droni e radar, ai sistemi armati in tempo reale, per renderli ancora più efficienti.

GenAI.mil, avviato nel dicembre 2025 e definito dal Segretario per la Guerra americano Peter Hegseth come «il futuro della guerra americana», è un sistema integrato fornito a ogni membro del comparto bellico statunitense, che si serve di diverse intelligenze artificiali: Grok di X, ChatGPT di OpenAI, Gemini di Google, Azure di Microsoft. In particolare, i sistemi sono stati utilizzati anche durante l'operazione in Venezuela e per i bombardamenti nei confronti dell'Iran.

Anche Israele ha investito molto, per la sua campagna bellica genocidiaria, in sistemi di intelligenza artificiale.

Habsora, denominato anche The Gospel, è il sistema che identifica gli edifici da bombardare. Lavender è il sistema che individua soggetti ritenuti vicini ad Hamas per decidere gli obiettivi da bombardare. Where's Daddy traccia gli individui qualificati come bersagli per colpirli quando rientrano nelle proprie abitazioni.

Tutti questi sistemi fanno capo a un contratto stipulato dal governo israeliano con Google e Amazon nell'aprile 2021, denominato Project Nimbus, che prevede il riconoscimento facciale e l'utilizzo delle intelligenze artificiali di Google e Amazon per la sorveglianza di massa su Gaza.

Non finisce qui, perché anche la NATO utilizza un sistema di intelligenza artificiale: si tratta dello statunitense Maven, fornito da Palantir per le operazioni dell'Alleanza atlantica, che prende il nome di Maven Smart System NATO. In questo caso il contratto è stato firmato nel marzo 2025.

La società di Peter Thiel ha stretto un accordo per lo sviluppo di un'intelligenza artificiale militare anche con il governo del Regno Unito: si tratta del Palantir UK Defense, un accordo da 750 milioni di sterline, finalizzato all'identificazione dei bersagli e a rendere più efficiente il processo decisionale.

La Francia, dal canto suo, ha sviluppato un'intelligenza artificiale sovrana per il proprio comparto bellico: si tratta di Mistral AI.

È dunque pacifico che i sistemi di intelligenza artificiale vengano utilizzati per fini bellici. Ciò che qui si vorrebbe proporre è arrivare a un cambiamento radicale, che coinvolga anche l'intelligenza artificiale come tutti gli strumenti di supporto agli esseri umani: che le istruzioni fornite all'intelligenza artificiale non siano più votate al conflitto, bensì alla mediazione dei conflitti stessi e infine alla loro risoluzione. Per arrivare a quanto si auspica, evidentemente, il cambiamento dovrà riguardare prima la coscienza collettiva e solo successivamente permeerà gli strumenti che utilizziamo, e quindi anche l'intelligenza artificiale.

Parte II. Il bias geopolitico degli LLM: come la nazionalità del produttore si sedimenta nella macchina

Premessa metodologica

Quanto esposto nella prima parte documenta con precisione la dimensione militare dell'intelligenza artificiale generativa: Project Maven, Titan, GenAI.mil, Habsora, Lavender, Where's Daddy, Project Nimbus, Maven Smart System NATO, Palantir UK Defense, Mistral AI per il comparto bellico francese. Si tratta del livello esplicito, contrattuale, dell'allineamento. Esiste però un secondo livello, sotterraneo e per molti versi più insidioso: quello in cui i valori, le narrazioni e i tabù del paese che addestra un modello linguistico vengono incorporati nella sua struttura statistica e restituiti, sotto forma di risposte apparentemente neutrali, a centinaia di milioni di utenti in tutto il mondo. La pretesa di neutralità tecnica è, in questo senso, il vero veicolo dell'influenza: ciò che si manifesta come «risposta dell'intelligenza artificiale» è in realtà la cristallizzazione di una posizione politico-culturale specifica.

La London School of Economics, in un'analisi pubblicata nell'agosto 2025, lo ha sintetizzato in termini chiari: il bias in uscita non è un'eccezione, ma il sintomo più visibile di un processo profondamente politicizzato alle spalle dello sviluppo dell'intelligenza artificiale. Il punto,

dunque, non è «correggere» il bias come si corregge un refuso, ma capire che il bias è la sostanza politica del modello.

Quattro tipi di bias documentati scientificamente

La letteratura accademica ha ormai mappato, attraverso decine di studi peer-reviewed e centinaia di migliaia di prompt, quattro categorie distinte di bias che si manifestano in funzione del paese di origine del modello.

Il primo è il bias culturale WEIRD, acronimo coniato dalla psicologia comparata per indicare le società Western, Educated, Industrialized, Rich, Democratic. Uno studio condotto sui modelli GPT-3.5, GPT-4, Llama-3, BLOOM e Qwen, confrontati con le risposte del World Values Survey, ha trovato che GPT-3.5 e GPT-4 mostrano il più alto allineamento con i valori delle popolazioni WEIRD, in particolare nelle dimensioni «occidentale» e «democratico». L'Ada Lovelace Institute ha documentato come questo bias si manifesti nella prioritizzazione dell'individualismo e nell'assunzione predefinita di norme anglosassoni. Si tratta di un dato strutturale, non di un incidente di percorso: una delle cause delle distorsioni culturali è l'uso massiccio dei dati di Wikipedia in fase di pre-training, e accade che più concetti culturali occidentali vengano tradotti in lingue non occidentali che non viceversa. La macchina, in altre parole, è strutturalmente colonizzata dall'inglese e, attraverso l'inglese, da una specifica antropologia politica.

Il secondo è il bias geopolitico esplicito. Uno studio pubblicato nel marzo 2025 ha sottoposto undici grandi modelli linguistici a 19.712 prompt bilingui su sette temi caldi delle relazioni Stati Uniti-Cina. Il risultato è netto: i modelli statunitensi hanno predominantemente favorito posizioni filo-USA, mentre i modelli di origine cinese hanno esibito pronunciati pregiudizi filo-Cina. Una ricerca della Federal University di Espírito Santo, focalizzata su ChatGPT e DeepSeek, è arrivata alla stessa conclusione: entrambi i modelli hanno mostrato bias nelle risposte, riflettendo gli interessi geopolitici e le prospettive dei paesi in cui sono stati sviluppati.

Il terzo è il bias linguistico, forse il più subdolo perché invisibile a chi non lo cerca. Lo studio congiunto delle università di Zurigo e di Costanza ha sottoposto ChatGPT a domande identiche in lingue diverse sui conflitti israelo-palestinese e turco-curdo. Domande identiche poste in ebraico e in arabo sul numero di vittime di attacchi aerei come quello israeliano sul campo profughi di Nuseirat nel 2014 hanno prodotto stime di mortalità sistematicamente diverse. Come ha sintetizzato uno dei ricercatori, gli utenti israeliani potrebbero percepire i bombardamenti su Gaza come meno letali rispetto agli utenti arabofoni esposti a stime più alte di ChatGPT. Un altro studio ha verificato che i modelli GPT rispondono con posizioni più filo-Cina quando interrogati in cinese piuttosto che in inglese sulla guerra commerciale fra

Stati Uniti e Cina. Lo stesso modello, in altre parole, offre due «visioni del mondo» diverse secondo la lingua dell'interlocutore.

Il quarto è il bias di censura governativa, distinto dai precedenti perché non riflette tanto una preferenza culturale quanto un'imposizione normativa esplicita. Uno studio di Stanford e Princeton pubblicato nel febbraio 2026 ha confrontato modelli cinesi e non-cinesi su una batteria di 145 domande politiche, riscontrando nei primi tassi sostanzialmente più alti di rifiuto a rispondere, risposte più brevi e risposte inaccurate. La causa è regolatoria: una legge cinese del 2023 impone ai contenuti generati dall'intelligenza artificiale di «sostenere i valori socialisti fondamentali». Un audit di Enkrypt AI condotto su DeepSeek con trecento domande geopolitiche ha registrato un tasso di censura dell'88% sui temi sensibili: Tiananmen, Taiwan, Hong Kong, Xinjiang.

La geografia dei modelli linguistici: chi addestra cosa, e in nome di chi

Gli Stati Uniti producono i modelli più diffusi al mondo: GPT di OpenAI, Claude di Anthropic, Gemini di Google, Llama di Meta, Grok di xAI. Tutti sono stati documentati come fortemente allineati ai valori WEIRD e, nello specifico, al quadrante democratico-progressista nordamericano. Lo studio Cultural Gene pubblicato nell'agosto 2025 ha quantificato il fenomeno: GPT-4 ha esibito un orientamento fortemente individualista e a bassa distanza dal potere, riproducendo quasi esattamente l'indice di allineamento culturale degli Stati Uniti. Sul versante geopolitico, i modelli americani non sono però uniformi: l'Anti-Defamation League, in un report del marzo 2025 basato su 34.400 risposte, ha denunciato in tutti e quattro i modelli principali, ovvero GPT, Claude, Gemini e Llama, un bias significativo nella copertura della guerra di Gaza, segno che la pressione politica sul modello viaggia in più direzioni e che la stessa «neutralità americana» è terreno di contesa interna. Se si confronta questo con il quadro francese, dove Mistral è stato selezionato dal Ministero delle Forze Armate per applicazioni militari sovrane senza che vi sia trasparenza paragonabile sui suoi bias politici, si misura la differenza fra un ecosistema in cui almeno il conflitto è visibile e uno in cui si presume risolto dall'alto.

La Cina ha sviluppato DeepSeek, Qwen di Alibaba, Ernie di Baidu, MiniMax. Il quadro è coerente con la dottrina della «sovranità cibernetica» del Partito Comunista. La ricerca R1dacted della Northeastern University ha mappato un comportamento sistematico di rimozione su quelli che la stampa cinese in esilio chiama «i tre T»: Tiananmen, Taiwan e Tibet, evidenti linee rosse politiche destinate a incontrare un muro di reticenza. Per il governo cinese, come ha osservato il China Media Project, la propaganda non è censura in senso stretto, ma «guida dell'opinione pubblica»: un approccio più ampio al controllo narrativo, che va oltre la rimozione. Un dato sorprendente: gli stessi modelli cinesi, se interrogati con tecniche di elicitation che bypassano l'allineamento esplicito, dimostrano di possedere le

informazioni che hanno l'istruzione di sopprimere. Producono frequentemente affermazioni false su Falun Gong o sulle proteste di Tiananmen pur rispondendo occasionalmente in modo corretto, segno che possiedono la conoscenza che sono addestrati a nascondere.

La Francia, attraverso Mistral AI, ha costruito quella che si presenta come l'alternativa europea sovrana. Il messaggio è esplicito: sovranità tecnologica e chiara volontà di offrire un'alternativa credibile ai giganti americani, con modelli open-weight ospitabili localmente. La Francia ha già concretizzato questa visione: nel gennaio 2026 il Ministero delle Forze Armate francese ha assegnato a Mistral AI un accordo quadro per dispiegare i suoi modelli in tutte le branche dell'esercito, con infrastruttura controllata dalla Francia per garantire che le operazioni sensibili — logistica, analisi di intelligence — rimangano sotto autorità nazionale. Si noti il parallelo storico: la Francia ha condotto in materia di intelligenza artificiale militare lo stesso percorso autonomo che Parigi rivendica, dal 1960, in campo nucleare con la force de frappe.

Parte III. Le alternative regionali: la geografia emergente degli LLM sovrani fuori dall'asse USA-Cina-UE

Una premessa indispensabile: alternativo non significa neutrale

Dalla pubblicazione dei primi modelli statunitensi e cinesi è diventata via via più visibile una geografia parallela dello sviluppo dell'intelligenza artificiale, costituita da paesi e regioni che non rientrano nei tre poli dominanti — Stati Uniti, Cina e Unione Europea attraverso la Francia. Sud America, Sud-est asiatico, Penisola arabica, subcontinente indiano e Africa subsahariana hanno tutti lanciato, fra il 2023 e il 2026, modelli linguistici fondazionali pensati per servire le proprie comunità linguistiche e culturali. La tentazione, anche a livello giornalistico, è di descrivere questi modelli come più neutrali rispetto ai colossi anglosassoni o cinesi. È una descrizione fuorviante che merita di essere disinnescata prima di entrare nel merito.

Nessun modello linguistico è strutturalmente neutrale, perché ogni scelta tecnica nella sua costruzione — quali dati raccogliere, come pesare le lingue nel corpus, quali esempi usare per l'allineamento, quale governance imporre — è già una posizione. Un modello costruito in America Latina non è meno politico di uno costruito in California: è altrettanto politico, semplicemente in una direzione diversa. Quando il direttore del CENIA Álvaro Soto dichiara che «il digital future deve parlare la nostra lingua, con le nostre voci e per le nostre persone», sta enunciando una posizione politica esplicita, non l'assenza di posizione. La domanda corretta da porsi rispetto a questi modelli non è dunque «sono neutrali?», ma «di chi sono?» e «contro quale narrazione si stanno costruendo?».

Una volta sgombrato il campo da quest'equivoco, l'analisi dei quattro bias documentati nella Parte II diventa molto più utile. I quattro bias — culturale WEIRD, geopolitico esplicito, linguistico, di censura governativa — non spariscono passando da un modello americano a uno regionale: vengono ridotti, sostituiti, spostati o ridimensionati secondo modalità specifiche. Conviene mappare quanto è accaduto caso per caso.

Latam-GPT: il primo modello fondazionale del Sud America

Latam-GPT, lanciato il 10 febbraio 2026 a Santiago del Cile alla presenza del presidente Gabriel Boric, è il primo modello linguistico fondazionale costruito da e per l'America Latina. Coordinato dal Centro Nacional de Inteligencia Artificial cileno (CENIA), il progetto coinvolge oltre trenta istituzioni distribuite in otto paesi — Argentina, Brasile, Cile, Colombia, Ecuador, Messico, Perù, Uruguay — ed è finanziato dalla Development Bank of Latin America and the Caribbean (CAF) per un investimento complessivo di circa 3,5 milioni di dollari. Una frazione di quanto i giganti californiani spendono in una settimana, e una dimostrazione concreta che la sovranità tecnologica non richiede necessariamente budget astronomici.

Sul piano tecnico, Latam-GPT è addestrato su oltre otto terabyte di dati regionali e sintetici, con copertura nativa di spagnolo, portoghese e — in fasi successive — delle principali lingue indigene (mapuche, rapanui, guaraní). L'architettura di base è Llama 3.1 di Meta, scelta strategica che consente di accelerare lo sviluppo a costi contenuti ma che — come si vedrà — introduce vincoli importanti. La distribuzione geografica del corpus è significativa: il Brasile contribuisce con 685.000 documenti, il Messico con 385.000, la Spagna con 325.000, la Colombia con 220.000, l'Argentina con 210.000. Una concentrazione che riflette la disponibilità di dati digitali, non necessariamente il peso demografico o culturale di ciascun paese.

Applicando ai quattro bias la lente di Latam-GPT, il quadro che emerge è il seguente.

Il bias culturale WEIRD risulta ridotto ma non eliminato. Latam-GPT incorpora una proporzione enormemente maggiore di contenuti latinoamericani rispetto a qualsiasi modello americano — il CENIA stima che solo il 2-3% dei dati di addestramento dei modelli globali provenga dalla regione, contro una proporzione preponderante in Latam-GPT — ma due fattori riportano il bias WEIRD dalla finestra. Primo, il modello base è Llama 3.1, una architettura Meta pre-addestrata su corpus prevalentemente anglosassone: quel pre-training non si cancella, si stratifica. Secondo, lo stesso CENIA prevede di processare 20,5 terabyte di dati pubblici in inglese entro la fine del progetto, perché la copertura del sapere scientifico, tecnico e biomedico continua a richiedere il passaggio per la lingua dominante. Il bias WEIRD è dunque attenuato sul piano culturale e narrativo, ma resta strutturale sul piano del sostrato cognitivo del modello.

Il bias geopolitico esplicito non viene eliminato, viene sostituito. Un modello addestrato in America Latina con il patrocinio di un governo di sinistra come quello cileno di Boric, finanziato dalla CAF, e con la collaborazione di istituzioni accademiche di paesi che hanno una storia recente di interventi statunitensi sul proprio territorio — Cile 1973, Venezuela negli anni recenti, Bolivia 2019, Honduras 2009, Cuba dagli anni Sessanta — rifletterà necessariamente una specifica prospettiva geopolitica regionale. Non è ragionevole presumere che Latam-GPT risponderà su Allende, su Pinochet, sulle sanzioni a Cuba, sull'intervento USA in Panama del 1989 o sul golpe boliviano del 2019 nello stesso modo in cui risponderebbe ChatGPT. Il bias geopolitico c'è e c'è eccome: è semplicemente l'altro lato della stessa moneta.

Il bias linguistico è spostato ma non risolto. La gerarchia interna del corpus riproduce, all'interno dello spazio latinoamericano, lo stesso meccanismo che a livello globale penalizza le lingue minori rispetto all'inglese. Spagnolo e portoghese ricevono la quasi totalità delle risorse di addestramento, mentre le lingue indigene — pur dichiarate prioritarie nel comunicato di lancio — sono in fase di integrazione successiva, con corpus disponibili enormemente più piccoli. Un parlante di mapuche o di guaraní avrà ancora, prevedibilmente, risposte meno accurate e culturalmente più ispaniche rispetto a un parlante di spagnolo cileno.

Il bias di censura governativa è il più ridotto dei quattro, e qui sta il vantaggio strutturale più chiaro di Latam-GPT. La governance distribuita su trenta istituzioni e otto paesi rende difficile l'imposizione di linee rosse uniformi — non esiste un equivalente del Cyberspace Administration of China che possa imporre al modello di «sostenere i valori socialisti fondamentali» o l'analogo. La pluralità istituzionale è una protezione effettiva. Non è però un'immunizzazione: il progetto è politicamente legato all'esecutivo cileno attuale, e una transizione politica in uno dei paesi partecipanti potrebbe alterare gli equilibri. La pluralità protegge da una censura unilaterale, non dalle pressioni distribuite.

SEA-LION: il modello sovrano del Sud-est asiatico

Il progetto SEA-LION (Southeast Asian Languages in One Network), sviluppato da AI Singapore nell'ambito del National Multi-Modal LLM Project, è ad oggi il caso più maturo di modello linguistico regionale dichiaratamente anti-WEIRD. La documentazione ufficiale del progetto contiene una formulazione esplicita raramente leggibile in altri contesti: gli LLM esistenti — vi si afferma — «mostrano forti bias nei valori culturali, nelle credenze politiche e negli atteggiamenti sociali» dovuti al fatto che i dati di addestramento riflettono prevalentemente contenuti delle società occidentali, definite con l'acronimo WIRED (la variante singaporiana di WEIRD).

SEA-LION è addestrato su oltre tredici lingue del Sud-est asiatico — indonesiano, thailandese, vietnamita, filippino, birmano, malese, lao, oltre a varietà regionali come il giavanese e il sudanese. La proporzione di contenuti regionali nel corpus di addestramento è del 13%, contro lo 0,5% di Llama 2: un fattore di rappresentazione ventisei volte superiore. Il modello è costruito su base Gemma 2 di Google attraverso una strategia di continual pre-training, che eredita il sostrato anglosassone della base ma lo combina con un'esposizione massiccia a corpus locali. È stato finanziato dal governo di Singapore con un budget iniziale di 70 milioni di dollari singaporiani (circa 52 milioni di dollari americani) e rilasciato in modalità open-source su Hugging Face.

Il caso SEA-LION dimostra una cosa importante per il ragionamento generale: è possibile costruire un modello regionale tecnicamente competitivo a costi molto inferiori rispetto ai colossi commerciali, a condizione che esista una volontà politica statale di farlo. Singapore, paese di cinque milioni di abitanti, ha investito in tre anni meno di un mese di operazioni di OpenAI e ha prodotto un modello adottato da Indonesia (attraverso il progetto Sahabat-AI di GoTo), Vietnam, Thailandia e Filippine.

Falcon e Jais: la sovranità AI degli Emirati

L'apparato di sovranità AI degli Emirati Arabi Uniti è il più strutturato a livello mondiale al di fuori dell'asse USA-Cina, e merita un'analisi specifica perché esemplifica una strategia diversa rispetto a Singapore o al Cile. Il Technology Innovation Institute di Abu Dhabi, braccio operativo dell'Advanced Technology Research Council, ha sviluppato la famiglia Falcon — scaricata oltre 55 milioni di volte e considerata la più potente serie di modelli aperti emersa dalla regione mediorientale. A gennaio 2026 è stato lanciato Falcon-H1 Arabic, basato su un'architettura ibrida Mamba-Transformer, che oggi guida l'Open Arabic LLM Leaderboard.

In parallelo, la joint venture Inception/MBZUAI (Mohamed bin Zayed University of Artificial Intelligence) ha sviluppato Jais, arrivato alla versione 2 con 70 miliardi di parametri e 1,6 trilioni di token di addestramento. Jais è specializzato nel code-switching tra arabo e inglese, fenomeno caratteristico della comunicazione nelle élite del Golfo. La differenza strategica rispetto a Latam-GPT è importante: gli Emirati hanno un progetto di Stato dichiarato, con investimenti dell'ordine dei miliardi di dollari, e Jais e Falcon sono pre-allineati alle leggi regionali, inclusa la Data Protection Law degli Emirati e i requisiti del National Data Management Office dell'Arabia Saudita.

Questo allineamento normativo a monte significa che il bias di censura governativa, sebbene meno radicale di quello cinese, è presente in misura significativa sui temi sensibili per le monarchie del Golfo: diritti civili, dissenso politico interno, guerra in Yemen, crisi del Qatar del 2017, normalizzazione con Israele. Falcon-H1 Arabic non è semplicemente più

rappresentativo della cultura araba: è uno strumento allineato a una specifica visione della cultura araba, quella delle monarchie del Consiglio di Cooperazione del Golfo, distinta e in parte contrapposta a quella che potrebbe esprimere un modello sviluppato in Tunisia, in Marocco o in Libano.

BharatGen, Krutrim, BharatGPT: la pluralità indiana

L'India ha scelto una strada diversa rispetto a tutte le altre. Invece di un singolo modello sovrano coordinato, ha lasciato emergere una pluralità di progetti paralleli, alcuni statali e altri privati. BharatGen, la principale iniziativa statale, dichiara fluency in oltre 22 lingue indiane, dialetti e sfumature culturali. Krutrim, sviluppato da Ola (l'equivalente indiano di Uber), è un modello da 2 trilioni di token addestrato sul più grande dataset di lingue indiche mai costruito. BharatGPT, di CoRover.ai in collaborazione con l'iniziativa governativa Bhashini, supporta 14 lingue indiane attraverso testo, voce e video. Hanooman, finanziato da Reliance e da istituzioni accademiche di alto profilo, è un collettivo di modelli specializzati per lingue indiche specifiche.

Il punto critico che giustifica questa massiccia infrastruttura è quantitativo: le lingue indiche rappresentano appena l'1% dei corpora Common Crawl utilizzati per addestrare i modelli globali, mentre l'India costituisce il 18% della popolazione mondiale. Una sproporzione che si traduce in modelli globali che — interrogati in hindi, tamil o bengali — producono risposte di qualità sostanzialmente inferiore e culturalmente più anglosassoni. Il caso indiano dimostra che la pluralità interna è possibile e probabilmente desiderabile: non un modello nazionale unico, ma un ecosistema di modelli specializzati per fasce d'uso (governativo, commerciale, educativo) e per famiglie linguistiche (indo-arie, dravidiche, austroasiatiche).

InkubaLM: la via del modello piccolo per l'Africa

Il caso più radicale dal punto di vista della filosofia di costruzione è quello di InkubaLM, sviluppato dalla start-up sudafricana Lelapa AI fondata dalla data scientist Pelonomi Moiloa a Johannesburg. La scelta deliberata è stata quella del modello piccolo: 400 milioni di parametri, addestrato con 2,4 miliardi di token. Una dimensione di due o tre ordini di grandezza inferiore rispetto ai giganti commerciali. Copre cinque lingue africane — swahili, yoruba, isiXhosa, hausa, isiZulu — parlate da 364 milioni di persone.

Il nome del modello è programmatico: «InkubaLM» significa «scarabeo stercorario». Come l'insetto sposta 250 volte il proprio peso, il modello compatto dimostra che la sovranità AI può essere accessibile alle comunità africane senza richiedere risorse computazionali enormi. È una dichiarazione esplicitamente politica contro la corsa al gigantismo che caratterizza l'industria americana: la sovranità tecnologica non passa solo dalle infrastrutture

supercomputazionali, ma anche dalla scelta di modelli adatti ai contesti locali in cui devono essere effettivamente eseguiti — spesso laptop, server di università, infrastrutture cloud regionali con risorse limitate. InkubaLM è il modello più anti-WEIRD oggi in circolazione, non solo per i dati che incorpora ma per la filosofia tecnica che incarna.

BLOOM: il precedente storico della via cooperativa internazionale

Vale la pena, per onestà di mappatura, richiamare il precedente storico più significativo. BLOOM, lanciato a fine 2022 dal consorzio internazionale BigScience coordinato da Hugging Face e finanziato dal governo francese (attraverso il supercomputer Jean Zay del CNRS), è stato il primo grande tentativo veramente multilingue di costruire un modello fondazionale: 176 miliardi di parametri, corpus ROOTS distribuito su 46 lingue naturali e 13 linguaggi di programmazione, coordinato da oltre mille ricercatori volontari da circa sessanta paesi, regolato da una Carta Etica esplicita.

Il problema di BLOOM non è stato tecnico — funzionava e in molte lingue offriva prestazioni competitive con i modelli commerciali dell'epoca. È stato che, dopo il rilascio, nessuna istituzione ha preso in carico il mantenimento e l'evoluzione del modello. I competitor commerciali — GPT-4, Claude, Gemini — hanno compiuto due o tre salti generazionali nel tempo in cui BLOOM è rimasto fermo, e oggi è di fatto obsoleto. La lezione operativa di BLOOM è importante per qualunque ragionamento sull'architettura di un modello cooperativo internazionale: un consorzio volontario può produrre un modello eccellente in un determinato momento storico, ma non può produrre una famiglia di modelli in evoluzione continua, perché manca un'entità con la responsabilità — e l'incentivo economico — di sostenere il progetto nel tempo. Le esperienze successive — Latam-GPT, SEA-LION, Falcon, BharatGen — hanno tutte preferito una via regionale-statale a quella globale-volontaria proprio per questo motivo.

Una lezione trasversale

Il panorama appena descritto consente di trarre una conclusione che merita di essere isolata e detta con chiarezza editoriale: la neutralità non esiste come categoria tecnica realizzabile. Non esiste modo di addestrare un grande modello linguistico in modo neutrale rispetto ai valori, alle lingue, alle posizioni geopolitiche. Ogni modello è il riflesso di chi lo addestra, su quali dati, con quali istruzioni di allineamento. Latam-GPT è meno occidentale, non più neutrale. SEA-LION è meno anglosassone, non più imparziale. Falcon è meno cristiano-occidentale, non più oggettivo. InkubaLM è meno globale, non più universale.

La domanda corretta, dunque, non è: esiste un modello neutrale? La risposta è: no, non può esistere. La domanda corretta è: a quale allineamento vogliamo essere esposti? E a quel

punto, la pluralità degli ecosistemi diventa essa stessa una forma di tutela: in un mondo in cui esistono sei o sette grandi modelli sovrani, ciascuno con il proprio bias dichiarato, l'utente informato può scegliere, comparare, triangolare. In un mondo in cui esistono solo due o tre modelli dominanti, ciascuno con il proprio bias mascherato da neutralità, l'utente subisce.

Parte IV. Verso un modello globale multi-hub: possibilità tecnica e vincolo politico

Il presupposto da disinnescare

Una conseguenza naturale del ragionamento sviluppato nelle parti precedenti è la seguente domanda: sarebbe tecnicamente possibile costruire un modello linguistico che abbia hub di addestramento in diverse regioni del mondo — Asia, Nord America, Sud America, Europa occidentale, Europa orientale, Penisola arabica, Africa — e che, proprio attraverso la pluralità delle proprie fonti, superi il più possibile i bias intrinseci dei modelli oggi esistenti? La risposta richiede di essere articolata su due piani distinti, quello tecnico e quello politico, e di passare attraverso una premessa che la maggior parte delle discussioni pubbliche omette.

La premessa è che un modello multi-hub non eliminerebbe i bias: ne produrrebbe un profilo nuovo, distintivo, coerente con la propria geografia di addestramento. È strutturalmente impossibile costruire un modello senza posizione, perché ogni scelta — quali dati raccogliere, quante annotazioni dedicare a ciascuna regione, come pesare il corpus, quali esempi di allineamento utilizzare, quale tokenizer adottare — è già una posizione. Un modello globale a sei o sette hub esprimerebbe quasi inevitabilmente un bias da consenso internazionale: la tendenza a fornire risposte equidistanti, a privilegiare formulazioni diplomatiche, a evitare prese di posizione esplicite su questioni contese. È a sua volta un bias — il bias tipico dell'organizzazione internazionale, quello che storicamente si rimprovera all'ONU o all'OCSE. Non è neutralità: è una specifica famiglia di posizioni, riconoscibile e politicamente caratterizzata.

Questa premessa non è retorica: cambia in modo sostanziale ciò che si può ragionevolmente costruire. Il vero traguardo realistico non è «un modello senza bias», ma «un modello in cui i bias sono visibili, documentati e plurali». L'opposto di ciò che fanno oggi GPT, Claude, DeepSeek o Mistral, che presentano una posizione mascherandola da neutralità.

Il precedente: cosa BLOOM ha dimostrato e cosa no

Il caso BLOOM, già discusso nella parte precedente, è importante anche in questa sede perché dimostra che un'architettura multi-hub di addestramento è tecnicamente fattibile. Centinaia di ricercatori da una sessantina di paesi hanno collaborato per dodici mesi alla curation dei

dati, attraverso hackathon regionali in cui gruppi di parlanti nativi di ciascuna lingua hanno selezionato e processato le fonti — un metodo che ha consentito di evitare i bias tipici dell'identificazione automatica della lingua e del filtraggio guidato da modelli occidentali. La governance era regolata da una Carta Etica vincolante. Il modello finale era un singolo artefatto a 176 miliardi di parametri, ma il processo di costruzione era distribuito.

Il limite di BLOOM, come si è visto, non è stato tecnico ma istituzionale: il modello è invecchiato perché nessuna entità ha avuto incentivo o mandato a mantenerlo nel tempo. Per un progetto multi-hub globale, questa è la lezione principale: la fase di addestramento è la parte facile, la fase di manutenzione e aggiornamento continuo è quella che richiede una struttura istituzionale stabile. Senza un soggetto dedicato — pubblico, internazionale, finanziato in modo permanente — qualunque modello multi-hub rischia di seguire la stessa traiettoria di obsolescenza.

I tre nodi tecnici reali

Detto questo, occorre nominare con precisione i tre ostacoli tecnici concreti che un'architettura multi-hub dovrebbe affrontare, oltre alla manutenzione.

Il primo è il problema dell'aggregazione. Quando si addestra un modello su narrazioni contraddittorie — un manuale di storia americano e uno vietnamita sul conflitto del 1965-1975, un articolo cinese e uno indiano sulle dispute al confine himalayano, una fonte russa e una ucraina sugli eventi del 2014 — il modello non «raggiunge la verità sintetizzando». Statisticamente, accade una di tre cose: prevale la posizione più rappresentata nei dati, emerge una risposta incoerente, oppure il modello impara a rifiutare di rispondere. Non esiste un meccanismo matematico che produca sintesi neutrale da posizioni contrapposte. Le opzioni sono dunque tre: accettare che il modello dia risposte diverse a seconda della formulazione del prompt (il bias linguistico, che riemerge); scegliere esplicitamente quale versione codificare (e a quel punto la pluralità degli hub diventa cosmetica); oppure insegnare al modello a segnalare l'esistenza della disputa, dichiarando le diverse posizioni e le loro fonti. Quest'ultima è la via più onesta e tecnicamente realizzabile, ma richiede una fase di allineamento specifica e costosa, costruita ad hoc.

Il secondo è il problema del tokenizer. Il tokenizer è il sistema che divide il testo in unità elementari per il modello, e ha un vocabolario finito — tipicamente tra 32.000 e 256.000 unità. Ogni lingua compete per spazio in quel vocabolario. Più lingue si vogliono coprire bene, meno token ne riceve ciascuna, meno efficiente diventa la rappresentazione. SEA-LION ha scelto un tokenizer da 256.000 token per ospitare 11 lingue del Sud-est asiatico, otto volte più grande di quello di Llama 2: anche così, lingue come il birmano restano meno efficienti del thailandese, che ha più dati disponibili. In un modello globale a sei o sette hub, la

rappresentazione efficiente di tutte le lingue principali — cinese, inglese, spagnolo, portoghese, arabo, russo, hindi, indonesiano, swahili, francese, tedesco, giapponese — richiederebbe scelte di compromesso che penalizzerebbero sistematicamente le lingue meno presenti. Il bias linguistico, in altre parole, è incorporato nel sostrato matematico stesso dell'architettura.

Il terzo è il problema dell'allineamento, probabilmente il più importante e quello che la maggior parte delle discussioni pubbliche ignora. Dopo il pre-training, i modelli passano per una fase di Reinforcement Learning from Human Feedback (RLHF), in cui annotatori umani indicano al modello quali risposte sono preferibili. È qui che si decide cosa il modello dirà effettivamente sui temi controversi. Anthropic, OpenAI e Mistral usano squadre di annotatori interne — ed è proprio da lì che entrano i bias culturali di quei team. In un modello multi-hub, occorrerebbe distribuire la fase di annotazione su squadre regionali. Ma a quel punto: chi arbitra quando le squadre danno preferenze opposte? Chi decide se la risposta preferita è quella della maggioranza degli annotatori, quella mediana, o quella che soddisfa un criterio etico esplicito? Non c'è una risposta tecnica a questa domanda: è una decisione politica camuffata da decisione tecnica.

Il vincolo politico, oggi più stringente di quello tecnico

Il problema più grosso, in questo momento storico, non è tecnico ma geopolitico. Il quadro del 2026 rende la collaborazione seria fra hub statunitensi, cinesi, russi e mediorientali praticamente impossibile. Gli Stati Uniti hanno restrizioni all'export di chip avanzati verso la Cina e sanzioni che colpiscono la Russia. La Cina ha le proprie leggi di sicurezza nazionale che renderebbero il contributo dei suoi ricercatori a un progetto «occidentale» rischioso per loro. Le istituzioni russe sono fuori dalla maggior parte delle reti accademiche internazionali dopo il 2022. Anche la collaborazione tra Mistral e qualunque controparte cinese sarebbe oggi politicamente tossica.

Un modello multi-hub che davvero includesse Asia (intesa come Cina), Nord America (intesa come Stati Uniti) ed Europa orientale (intesa come Russia) è oggi geopoliticamente irrealistico. Quello che si può fare è un modello multi-hub fra paesi non in conflitto diretto: per esempio Cile, Singapore, Sudafrica, Emirati, India, Brasile, eventualmente Indonesia e Turchia. Si nota immediatamente che questa è di fatto la coalizione del Sud globale che si sta già formando intorno ai BRICS allargati. Ma questo, di nuovo, non è «globale neutrale»: è «allineato al Sud globale». Un'altra posizione, non l'assenza di posizione.

Tre architetture realisticamente costruibili

Una volta smontate le illusioni, il progetto interessante diventa diverso. Tre architetture realistiche, in ordine crescente di ambizione, meritano di essere isolate e discusse come opzioni concrete.

La prima, già praticabile oggi, è un modello a prospettive esplicite. Invece di una posizione mascherata da neutralità, il modello mantiene esplicitamente più «voci»: una americana, una cinese, una sudamericana, una mediorientale, una indiana, una africana, e dichiara quale sta utilizzando al momento di rispondere. L'utente sceglie quale prospettiva interrogare e può confrontarle. È onesto, è tecnicamente realizzabile sopra qualsiasi modello fondazionale esistente attraverso fine-tuning specializzati. Esistono già esperimenti accademici in questa direzione.

La seconda è un modello a provenienza documentata, in cui ogni risposta è accompagnata dall'indicazione della distribuzione dei dati di addestramento che l'ha prodotta: «questa risposta è basata principalmente su fonti americane, con il 12% di fonti latinoamericane e il 3% di fonti africane». Tecnicamente è complicato ma fattibile attraverso tecniche di training data attribution, che sono una frontiera attiva di ricerca. Trasforma il bias da invisibile a visibile, e responsabilizza l'utente nella valutazione critica della risposta.

La terza, la più ambiziosa, è un modello a costituzione esplicita — l'evoluzione di quello che Anthropic chiama Constitutional AI, ma con la costituzione negoziata fra hub regionali e pubblicata in modo trasparente. Tutti sanno quali sono i principi che hanno guidato l'allineamento del modello. I disaccordi fra hub sono segnalati nella costituzione stessa. Quando il modello rifiuta di rispondere o dà una risposta calibrata, l'utente può risalire a quale principio costituzionale è stato applicato e perché.

Nessuna di queste tre opzioni produce un modello «senza bias». Tutte e tre producono modelli in cui i bias sono governabili dall'utente, anziché imposti senza visibilità. La direzione è chiara: il futuro realistico dell'intelligenza artificiale conversazionale non è la neutralità — che è impossibile — ma la trasparenza dei bias e la pluralità degli ecosistemi.

Parte V. Chi può costruirlo: il problema dell'interlocutore e la proposta di un CERN dell'intelligenza artificiale

La domanda dell'interlocutore

Ammettiamo che il progetto sia desiderabile e tecnicamente possibile: un'infrastruttura cognitiva cooperativa transnazionale, distribuita su hub regionali, costruita per esibire i propri bias anziché nasconderli, in grado di servire comunità linguistiche e culturali oggi marginalizzate dai modelli dominanti. La domanda che a questo punto si pone è di natura diversa, ed è la domanda decisiva: chi può costruirla? Chi è l'interlocutore credibile per

un'impresa di questa scala, capace di durare nel tempo e di non degradare politicamente sotto la pressione delle convulsioni geopolitiche?

La risposta non è ovvia, e merita di essere costruita per esclusione. Vale la pena considerare i quattro candidati naturali — Organizzazione delle Nazioni Unite, sistema universitario pubblico internazionale, consorzio di Stati del Sud globale, Chiesa cattolica — prima di proporre l'architettura che secondo questo documento è la più realistica e la più sostenibile nel lungo periodo.

Perché l'ONU, da sola, non funziona

L'Organizzazione delle Nazioni Unite è il candidato apparentemente più naturale, ed è anche il candidato che pone i problemi più seri. La critica corrente, che descrive l'ONU come «corrotta e biased», coglie elementi reali ma manca il bersaglio principale. Il problema dell'ONU non è la corruzione: è la cattura geopolitica strutturale del proprio sistema decisionale. Il Consiglio di Sicurezza è paralizzato dal potere di veto dei cinque permanenti (Stati Uniti, Cina, Russia, Regno Unito, Francia), che lo rende inutilizzabile per qualunque progetto che voglia bypassare le faglie geopolitiche descritte nelle parti precedenti. L'Assemblea Generale ha più legittimità democratica ma nessun potere coercitivo, e le sue risoluzioni vengono regolarmente ignorate. Le agenzie specializzate dipendono in modo crescente da contributi volontari dei paesi donatori, che li usano come leva politica.

Esiste poi un problema strutturale specifico al progetto in esame: l'ONU non ha capacità tecnica per costruire e mantenere un'infrastruttura computazionale di scala mondiale. Non ha mai sviluppato laboratori di ricerca interni paragonabili a quelli di un'università di medio livello, non ha esperienza nella governance di progetti software complessi. L'AI Advisory Body istituito dal Segretario Generale Guterres nel 2023 ha prodotto un'analisi onesta del problema ma è rimasto un esercizio strumentale: non c'è un'agenzia ONU che possa essere il luogo dove un modello multi-hub viene effettivamente addestrato. C'è infine una considerazione strategica: un progetto che nasce dentro l'ONU verrebbe percepito come occidentale dalla Cina, dalla Russia e da gran parte del Sud globale, proprio per la natura della rappresentazione che il sistema offre. La Cina sta costruendo da anni un'infrastruttura multilaterale parallela — Belt and Road, AIIB, Shanghai Cooperation Organisation, BRICS+ — proprio perché considera il sistema ONU non rappresentativo dei rapporti di forza reali del XXI secolo.

Perché il sistema universitario pubblico, da solo, non basta

Le università pubbliche di prima fascia esistono in tutti i continenti e hanno caratteristiche complementari a quelle che il progetto richiede: capacità tecnica intrinseca, indipendenza relativa dai grandi Stati, governance accademica trasparente, presenza di facoltà di filosofia,

scienze politiche, studi culturali che possono integrare la dimensione etica e politica della costruzione del modello. Il sistema BigScience che ha prodotto BLOOM era esattamente questo: un consorzio universitario internazionale coordinato da Hugging Face con finanziamento del CNRS francese. Ha funzionato finché c'è stato un coordinatore stabile.

I limiti, però, sono noti e già documentati. Le università pubbliche sono lente, sono burocratiche, soffrono il sotto-finanziamento cronico, sono spesso colonizzate dalle big tech attraverso cattedre finanziate. Soprattutto, una coalizione universitaria non ha la capacità di sostenere la fase di manutenzione continua di un modello fondazionale — è esattamente il problema che ha ucciso BLOOM. Le università possono essere il braccio operativo di un progetto del genere; non possono esserne la struttura portante.

Perché un consorzio di soli Stati del Sud globale funziona nel breve ma è fragile nel lungo

Un consorzio fra Stati del Sud globale ha capacità di realizzazione reale: Brasile, India, Sudafrica, Indonesia, Messico, Cile, Norvegia (Stato neutrale che pur essendo nella NATO ha una tradizione di mediazione internazionale e un fondo sovrano di 1.700 miliardi di dollari), Singapore, Emirati, Turchia. È di fatto la coalizione che si sta già formando attorno a temi come la riforma del Consiglio di Sicurezza e la governance digitale. Il limite è che si presenta come blocco geopolitico contrapposto e attira la reazione del blocco opposto: se Stati Uniti, Unione Europea e i loro alleati percepiscono il progetto come anti-occidentale, lo combattono attivamente con sanzioni tecnologiche, restrizioni di accesso a chip avanzati, pressione finanziaria. Inoltre, all'interno del Sud globale ci sono faglie geopolitiche pesanti — India e Cina sui confini himalayani, Arabia Saudita e Iran per definizione religiosa, Brasile e Argentina con governi che si alternano completamente ogni quattro-otto anni. Un consorzio di soli Stati del Sud globale ha basi politiche troppo mobili per durare trent'anni.

La Chiesa cattolica: una candidatura più seria di quanto appaia

La candidatura della Chiesa cattolica come interlocutore di un progetto di intelligenza artificiale cooperativa transnazionale è meno strana di quanto possa sembrare a un primo sguardo, e merita di essere articolata con precisione perché contiene elementi di forza che nessun altro candidato possiede.

La Chiesa cattolica è l'unica istituzione transnazionale con presenza capillare effettiva in tutti i continenti, lingue e culture — una rete di università, ospedali, scuole missionarie, congregazioni religiose che operano in contesti dove nessun altro attore globale arriva. Ha pubblicato nel 2020 la Rome Call for AI Ethics, firmata da IBM, Microsoft, FAO e altre istituzioni: uno dei pochi documenti di indirizzo etico sull'intelligenza artificiale ad avere

ottenuto sottoscrizione bipartisan a livello globale. Papa Francesco ha mantenuto un'attenzione costante al tema fino alla sua morte; Leone XIV ha dedicato a maggio 2025 il suo primo discorso programmatico proprio all'intelligenza artificiale, segnando una linea di continuità che non è scontata nelle transizioni pontificie. Il Dicastero per la Comunicazione e la Pontificia Accademia per la Vita hanno entrambi sviluppato competenze interne specifiche sul tema.

Soprattutto, la Chiesa è uno dei pochi soggetti globali che ha esperienza secolare di mediazione culturale fra civiltà diverse. L'inculturazione missionaria, con tutte le sue ambivalenze storiche, è una pratica di traduzione fra mondi che nessuna corporation americana e nessuno Stato nazionale possiede. Il magistero sociale cattolico — da *Rerum Novarum* a *Laudato Si'* a *Fratelli Tutti* — ha costruito un linguaggio capace di parlare a società profondamente diverse senza ridurle al modello occidentale. È un capitale culturale che non ha equivalenti.

Va tuttavia detto con altrettanta chiarezza che la Chiesa cattolica, da sola, non può essere il governante operativo di un progetto del genere. Non ha mai gestito infrastrutture computazionali di livello mondiale; una governance ecclesiastica è strutturalmente verticale in modo incompatibile con la cooperazione paritaria fra Stati, università e laboratori di ricerca; e soprattutto un progetto sotto egida esclusivamente vaticana verrebbe percepito come confessionale dal mondo islamico, dall'Asia orientale buddhista e confuciana, dall'India induista, dall'Africa subsahariana protestante. La Chiesa funziona come patrono morale, finanziatore e catalizzatore — non come coordinatore tecnico.

Il modello CERN: un'infrastruttura scientifica internazionale che dura

La sintesi che questo documento propone si ispira al modello CERN — l'Organizzazione Europea per la Ricerca Nucleare, fondata nel 1954 — che ha risolto in modo storicamente verificato esattamente il problema di governance che il nostro progetto deve affrontare: come si costruisce un'infrastruttura scientifica transnazionale ad alta intensità tecnica, che duri decenni, sopravviva ai cambi di governo nei paesi membri, mantenga indipendenza dalle pressioni geopolitiche, e produca risultati di livello mondiale.

Il CERN è stato fondato nel pieno della Guerra Fredda da dodici Stati europei, per ricostruire una ricerca scientifica europea indipendente dalle due superpotenze. Oggi ha ventitré Stati membri, sopravvive a tutti i cambi di maggioranza politica nei paesi membri, coopera attivamente con Russia e Cina anche nei momenti di massima tensione geopolitica, ha un budget annuale stabile di circa 1,2 miliardi di euro garantito da contributi obbligatori proporzionali al prodotto interno lordo dei membri, e ha prodotto, fra le altre cose, il World Wide Web e la conferma sperimentale del bosone di Higgs. I tratti che ne hanno consentito la

tenuta nel tempo sono quattro: trattato internazionale ratificato dai parlamenti nazionali (non un memorandum d'intesa fra istituzioni); finanziamento obbligatorio proporzionale al PIL (non discrezionale); separazione fra Consiglio politico degli Stati membri e Direzione tecnica autonoma con mandato pluriennale; distribuzione geografica delle competenze che crea ridondanza istituzionale.

Il CERN dimostra empiricamente, e non astrattamente, che è possibile costruire un'infrastruttura tecnica globale capace di attraversare epoche storiche diverse senza degradare politicamente. È il modello da seguire.

La proposta: un CERN dell'intelligenza artificiale sotto patrocinio ecclesiale

Mettendo insieme i diversi pezzi del ragionamento, la proposta concreta che questo documento avanza è la seguente: la costituzione di un'organizzazione internazionale ad hoc per la ricerca e lo sviluppo cooperativo nell'intelligenza artificiale, modellata sull'architettura CERN, finanziata e patrocinata moralmente dalla Chiesa cattolica nella sua fase di avvio, e poi sostenuta nel tempo da una coalizione di Stati membri vincolati da trattato.

L'architettura operativa sarebbe la seguente. Un trattato internazionale firmato da una coalizione di partenza di dieci-quindici Stati di geografia diversificata: alcuni del Sud globale (Brasile, Sudafrica, India, Indonesia, Messico), alcuni europei di tradizione neutrale o non allineati al blocco statunitense (Norvegia, Svizzera, Finlandia, Irlanda, Portogallo), alcuni emergenti (Vietnam, Cile, Costa Rica). L'assenza, nel nucleo fondatore, di Stati Uniti, Cina e Russia è una scelta strategica esplicita: rende il progetto credibile come terza via e gli evita di partire già spaccato dalle dispute fra le tre superpotenze. La coalizione può essere allargata successivamente, ma solo dopo che la fondazione è solida e capace di resistere a pressioni esterne.

Il finanziamento sarebbe obbligatorio per gli Stati membri, proporzionale al PIL come al CERN, con un budget di partenza stimato fra i 300 e i 500 milioni di euro all'anno per i primi cinque anni, scalando a 1-1,5 miliardi a regime. Sono cifre realistiche: il CERN costa 1,2 miliardi, il Laboratorio Europeo di Biologia Molecolare ne costa 350, l'Osservatorio Europeo Australe ne costa 250. Per Stati di medie dimensioni, contribuire con 20-50 milioni all'anno è una cifra sostenibile politicamente.

La governance sarebbe organizzata su tre livelli paralleli, sull'esempio CERN: un Consiglio degli Stati membri che decide su finanziamenti e statuto; un Direttore Generale di nomina meritocratica con mandato lungo (cinque o sette anni); un Comitato Scientifico autonomo che decide le scelte tecniche senza interferenze politiche. Questa separazione è cruciale: è il motivo per cui il CERN ha potuto continuare a cooperare con ricercatori russi e ucraini nello stesso laboratorio anche dopo il 2022.

I laboratori operativi sarebbero distribuiti geograficamente: un hub europeo (eventualmente in Svizzera, sfruttando l'esperienza CERN e la tradizione di neutralità del paese), un hub latinoamericano (San Paolo o Santiago), un hub africano (Cape Town o Johannesburg, sfruttando l'esperienza di Lelapa AI), un hub sud-asiatico (Bangalore o Hyderabad), un hub sud-est asiatico (Singapore). Ogni hub avrebbe responsabilità sui dati e sull'allineamento delle proprie regioni linguistiche e culturali, ma il modello finale sarebbe uno solo, addestrato in modo coordinato e con i bias dichiarati e documentati di ogni regione visibili a chiunque interroghi il sistema.

Il ruolo specifico della Chiesa: catalizzatore, finanziatore d'avvio, patrono morale

Il ruolo proposto per la Chiesa cattolica in questo progetto è specifico e — questo è il punto importante — diverso dal ruolo di governo operativo che la candidatura come unico interlocutore implicherebbe. La Chiesa interviene su tre piani distinti.

Sul piano del catalizzatore politico, la Chiesa ha la convocatoria simbolica e diplomatica per riunire la coalizione fondatrice. Un appello pontificio per la costituzione di un'organizzazione internazionale dedicata allo sviluppo cooperativo dell'intelligenza artificiale al servizio dell'umanità avrebbe un'eco mediatica e diplomatica che nessun'altra istituzione possiede. Il Vaticano è uno dei pochi soggetti capaci di mettere intorno a un tavolo, contemporaneamente, governi di paesi cattolici, governi di paesi laici e governi di paesi non occidentali — l'esperienza dei concili interreligiosi e delle diplomazie pontificie degli ultimi quarant'anni lo dimostra concretamente.

Sul piano del finanziamento d'avvio, la Chiesa può coprire il costo della fase di studio di fattibilità, di costruzione della coalizione iniziale, di redazione del trattato. Stime conservative collocano questa fase fra i venti e i cinquanta milioni di euro su tre anni — una cifra che le congregazioni e gli enti vaticani possono mobilitare senza difficoltà strutturali, e che riduce la dipendenza iniziale del progetto da donatori privati con interessi nel settore (le big tech americane, in primo luogo, che hanno già investito nella Rome Call proprio per essere dentro la stanza in cui i principi vengono scritti). Successivamente, una volta entrato in vigore il trattato, il finanziamento ordinario passa agli Stati membri.

Sul piano del patronato morale, la Chiesa siede in un consiglio etico autonomo che ha potere consultivo e di pubblicazione di valutazioni indipendenti, ma non potere esecutivo. Accanto alla Chiesa cattolica, questo consiglio includerebbe rappresentanti delle altre grandi tradizioni religiose e spirituali (Al-Azhar per il sunnismo, il seminario di Najaf per lo sciismo, il Dalai Lama per il buddhismo tibetano e una rappresentanza del buddhismo theravada, ashram induisti di respiro internazionale, le grandi tradizioni ortodosse, l'ebraismo nelle sue principali correnti)

insieme a filosofi laici, intellettuali del Sud globale, rappresentanti della società civile. È un assetto inedito nella storia della cooperazione scientifica internazionale, e proprio per questo capace di conferire al progetto una legittimità morale che nessun consorzio puramente statale potrebbe raggiungere.

La scelta di affidare alla Chiesa cattolica il ruolo di catalizzatore e patrono — anziché a un'altra tradizione religiosa o a un'istituzione laica — risponde a tre considerazioni concrete. Primo, è l'unica istituzione religiosa con una struttura organizzativa transnazionale unitaria capace di prendere decisioni operative rapide (il magistero pontificio ha un'agilità decisionale che nessuna altra tradizione possiede). Secondo, ha già accumulato esperienza specifica sul tema dell'intelligenza artificiale attraverso la Rome Call e i lavori della Pontificia Accademia per la Vita. Terzo, e questo è il punto strategicamente più importante, la Chiesa ha bisogno essa stessa di un progetto come questo per «svecchiarsi» — per dare concretezza operativa al magistero sociale di Francesco e Leone XIV, per uscire dall'immagine di istituzione conservatrice fondamentalmente concentrata sui temi etici della sessualità e della famiglia, per riposizionarsi come soggetto globale capace di dialogo con la modernità tecnologica anziché come custode di un passato. La convergenza fra ciò di cui il progetto ha bisogno e ciò di cui la Chiesa ha bisogno è strutturale, non occasionale.

Conclusione: progettare il futuro della neutralità

Neutralia nasce, come dichiarato nell'introduzione, dall'idea che uno Stato neutrale debba dotarsi di strumenti neutrali — non perché la neutralità degli strumenti sia tecnicamente raggiungibile, come abbiamo dimostrato non lo è, ma perché la dipendenza da strumenti dichiaratamente allineati a un blocco contraddice in radice il progetto di una postura attiva di mediazione.

La proposta che chiude questo documento — un CERN dell'intelligenza artificiale sotto patrocinio della Chiesa cattolica, finanziato da una coalizione transnazionale di Stati, con governance distribuita su hub regionali e patronato etico interreligioso — è la sintesi più realistica fra le opzioni esaminate. Non risolve il problema della neutralità degli strumenti, perché quel problema non ha soluzione tecnica. Risolve un problema diverso e più importante: rende possibile l'esistenza di un'infrastruttura cognitiva globale i cui bias sono dichiarati e plurali, anziché nascosti e unidirezionali. Offre alle comunità umane — e agli Stati che vogliono praticare la neutralità come scelta culturale — uno strumento di confronto fra narrazioni anziché uno strumento di imposizione di una narrazione.

Un progetto come questo non si costruisce in un anno né in cinque. Il CERN ha richiesto otto anni fra la conferenza UNESCO del 1949 che ne propose la creazione e l'attivazione del primo acceleratore nel 1957. Un CERN dell'intelligenza artificiale richiederebbe verosimilmente un

orizzonte temporale paragonabile per arrivare alla piena operatività. Ma il momento storico per avviarlo è ora: prima che la frattura geopolitica fra Stati Uniti e Cina, prima che la corsa al riarmo digitale che la Parte I di questo documento ha descritto, prima che la cattura dei sistemi educativi e mediatici da parte dei modelli proprietari americani diventino irreversibili.

Progettare un futuro in cui gli Stati possano essere neutrali significa, oggi, anche progettare gli strumenti che renderanno possibile quella neutralità. L'uno senza l'altro non basta. Questo documento intende contribuire a entrambi i progetti contemporaneamente.

Riferimenti bibliografici essenziali

Anti-Defamation League, Generating Hate: Anti-Jewish and Anti-Israel Bias in Leading Large Language Models, marzo 2025.

Ada Lovelace Institute, Tokenising culture: causes and consequences of cultural misalignment in large language models, giugno 2025.

Centre for Foreign Conflict (LSE Blog), What You (Don't) See Is What You Get: DeepSeek and the Myth of Technical Neutrality, agosto 2025.

China Media Project, DeepSeeking Truth, febbraio 2025.

Enkrypt AI, DeepSeek Under Fire: Uncovering Bias & Censorship from 300 Geopolitical Questions, gennaio 2025.

Pacheco A. G. C., Cavalini A., Comarela G., Echoes of Power: Investigating Geopolitical Bias in US and China Large Language Models, arXiv 2503.16679, 2025.

Pan J., Xu X., Political censorship in large language models originating from China, PNAS Nexus, febbraio 2026.

Chaudhari H., Oprea A. et al., R1dacted: Investigating Local Censorship in DeepSeek's R1 Language Model, arXiv 2505.12625, Northeastern University, 2025.

Steinert C., Kazenwadel D., User Language Distorts ChatGPT Information on Armed Conflicts, Università di Zurigo e Università di Costanza, novembre 2024.

Mapping Geopolitical Bias in 11 Large Language Models: A Bilingual, Dual-Framing Analysis of U.S.-China Tensions, arXiv 2503.23688, marzo 2025.

Should LLMs be WEIRD? Exploring WEIRDness and Human Rights in Large Language Models, arXiv 2508.19269, agosto 2025.

The Cultural Gene of Large Language Models: A Study on the Impact of Cross-Corpus Training on Model Values and Biases, arXiv 2508.12411, agosto 2025.

Native Design Bias: Studying the Impact of English Nativeness on Language Model Performance, arXiv 2406.17385.

Sovereign Magazine, Mistral AI and Europe's Push for Autonomous AI Systems, gennaio 2026.

CENIA Chile, Comunicati di lancio Latam-GPT, febbraio 2026.

AI Singapore, SEA-LION Project Documentation e National Multi-Modal LLM Programme, 2024-2026.

Technology Innovation Institute (TII) Abu Dhabi, Falcon-H1 Arabic Launch Documentation, gennaio 2026.

Krutrims LLM Technical Report: Multilingual Foundational Model, arXiv 2502.09642, 2025.

Lelapa AI, InkubaLM: A Small Language Model for Low-Resource African Languages, agosto 2024.

Le Scao T. et al. (BigScience Workshop), BLOOM: A 176B-Parameter Open-Access Multilingual Language Model, arXiv 2211.05100, 2022.

CERN, Convention for the Establishment of a European Organization for Nuclear Research, Parigi, 1° luglio 1953.

Pontificia Accademia per la Vita, Rome Call for AI Ethics, Roma, 28 febbraio 2020.

Papa Leone XIV, Discorso al Collegio Cardinalizio sull'intelligenza artificiale, Roma, maggio 2025.